
SELF-TAUGHT LEARNING AVEC DES AUTO-ENCODEURS

Nom et Prénom: Badreddine Malek

Classe: GI2 S2

Lien: <https://colab.research.google.com/drive/1nNA7VeTqbTj4l-aMOxSOKnhoiUdfXeqR?usp=sharing>

1 Introduction

L'objectif de ce rapport est de présenter les observations et les résultats obtenus en utilisant l'apprentissage autonome avec des auto-encodeurs pour la classification. Nous avons utilisé le jeu de données MNIST, qui est un ensemble d'images de chiffres manuscrits, pour entraîner notre modèle de classification.

2 Performance du modèle

Nous avons commencé par diviser le jeu de données en ensembles étiquetés et non étiquetés. Les données étiquetées sont utilisées pour entraîner le modèle de classification, tandis que les données non étiquetées sont utilisées pour entraîner un auto-encodeur. L'idée principale de l'apprentissage autonome est d'utiliser l'auto-encodeur pour apprendre une représentation latente des données non étiquetées, puis d'utiliser cette représentation pour améliorer les performances du modèle de classification.

Nous avons utilisé des auto-encodeurs convolutionnels pour extraire les caractéristiques des images non étiquetées. Ensuite, nous avons combiné ces caractéristiques avec les données étiquetées pour entraîner un modèle de classification supervisée. Les résultats ont montré que le modèle sans les caractéristiques d'auto-encodeur a obtenu une exactitude de test de 0.952, surpassant le modèle avec les caractéristiques d'auto-encodeur qui a atteint une exactitude de 0.917. Ces résultats suggèrent que, pour ce jeu de données et cette implémentation spécifiques, l'ajout des caractéristiques d'auto-encodeur n'a pas amélioré les performances de classification.

3 Avantages de l'apprentissage auto-supervisé avec les auto-encodeurs

Malgré les résultats mitigés obtenus dans cette expérience, le self-taught learning avec les auto-encodeurs présente plusieurs avantages potentiels :

3.1 Exploitation de données non étiquetées

Les auto-encodeurs permettent d'exploiter des ensembles de données non étiquetées, souvent plus abondantes que les données étiquetées, pour améliorer les performances sur des tâches supervisées.

3.2 Extraction de caractéristiques pertinentes

Les auto-encodeurs peuvent apprendre à extraire des caractéristiques pertinentes des données d'entrée, y compris des caractéristiques que l'humain n'aurait pas nécessairement identifiées.

3.3 Approche non supervisée

Cette méthode ne nécessite pas d'étiquettes coûteuses ou difficiles à obtenir pour l'ensemble du jeu de données.

3.4 Amélioration potentielle avec des données étiquetées limitées

Lorsque les données étiquetées sont limitées, l'utilisation de caractéristiques extraites à partir de données non étiquetées peut améliorer les performances de classification.

4 Limitations observées

Cependant, cette expérience a également mis en évidence certaines limitations de l'approche de self-taught learning avec les auto-encodeurs :

4.1 Caractéristiques non optimales

Les caractéristiques extraites par l'auto-encodeur ne sont pas nécessairement les plus pertinentes ou optimales pour la tâche de classification spécifique.

4.2 Perte d'informations

Le processus d'encodage et de décodage peut entraîner une perte d'informations pertinentes pour la classification, ce qui dégrade les performances du modèle.

4.3 Dépendance à l'architecture

Les performances dépendent fortement de l'architecture des modèles d'auto-encodeur et de classification, ainsi que de la méthode d'extraction et de fusion des caractéristiques.

4.4 Performances limitées sur des tâches simples

Pour des tâches ou des jeux de données relativement simples, comme MNIST, l'ajout de caractéristiques d'auto-encodeur peut ne pas apporter d'améliorations significatives par rapport à un modèle de classification standard.

5 Suggestions d'amélioration

Afin de tirer un meilleur parti du self-taught learning avec les auto-encodeurs, plusieurs pistes d'amélioration peuvent être envisagées :

5.1 Exploration d'architectures d'auto-encodeurs alternatives

Expérimenter avec différentes architectures d'auto-encodeurs, telles que les auto-encodeurs convolutionnels (CAEs), les auto-encodeurs variationnels (VAEs) ou les auto-encodeurs débruitants, pourrait permettre de capturer des caractéristiques plus pertinentes pour la tâche de classification.

5.2 Optimisation de l'auto-encodeur pour la classification

Optimiser spécifiquement l'auto-encodeur pour la tâche de classification, en utilisant par exemple une fonction de perte personnalisée ou une régularisation adaptée, pourrait améliorer la pertinence des caractéristiques extraites.

5.3 Combinaison avec les données d'entrée

Au lieu de remplacer complètement les données d'entrée par les caractéristiques d'auto-encodeur, les combiner avec les données d'entrée originales pourrait permettre de conserver davantage d'informations pertinentes.

5.4 Méthodes d'extraction et de fusion des caractéristiques

Explorer différentes méthodes d'extraction et de fusion des caractéristiques issues de l'auto-encodeur avec les données d'entrée, comme la concaténation, les modèles multi-branches ou l'attention, pourrait améliorer les performances.

6 Conclusion

En conclusion, bien que les résultats de cette expérience n'aient pas montré d'amélioration avec l'utilisation des caractéristiques d'auto-encodeur pour la classification d'images MNIST, le self-taught learning avec les auto-encodeurs reste une approche prometteuse, en particulier pour les tâches plus complexes où les données étiquetées sont limitées. Des ajustements de l'architecture, des hyperparamètres, des méthodes d'extraction et de fusion des caractéristiques, ainsi que des tests sur des jeux de données plus complexes, pourraient permettre de mieux exploiter le potentiel des auto-encodeurs pour l'extraction de caractéristiques pertinentes dans de futurs travaux.